

Київський національний університет імені Тараса Шевченка
Механіко-математичний факультет
Спеціальність “Статистика”, 2 курс, група 1
Проект з мов програмування c/c++
Тема: 13. “Histogram”
Виконали:

Ангеліна Рябой
Аліна Стратійчук

Завдання 13 «Histogram» полягає у створенні структури для роботи з гістограмою частот мовами програмування C та C++. У ході виконання роботи ми реалізували методи для додавання чисел до гістограми, роботи з текстовими та бінарними файлами, а також обчислення статистичних характеристик: середнього значення, медіани, дисперсії, середнього відхилення, асиметрії, ексцесу, моди, розмаху та критерію Пірсона для перевірки нормального розподілу даних.

Гістограма — це спосіб представлення даних, де всі значення діляться на інтервали, а для кожного інтервалу рахується кількість елементів, що в нього потрапили. У програмі ці кількості зберігаються у масиві frequency. У реалізованій структурі гістограма задається мінімальним значенням min_hist, максимальним значенням max_hist та кількістю інтервалів M.

Ширина одного інтервалу обчислюється за формулою:

$$h = \frac{b - a}{K}$$

де:

- h — ширина одного інтервалу;
- a — мінімальне значення даних (min_hist);
- b — максимальне значення даних (max_hist);
- K — кількість інтервалів (M).

У коді це реалізовано так:

```
double width = (max_hist - min_hist) / M;
```

Інтервали гістограми задаються за допомогою меж, які рівномірно розподіляються на всьому проміжку [a,b].

Межі інтервалів визначаються за формулою:

$$t_i = a + i \cdot h$$

де:

- t_i — межа i-го інтервалу;
- a — мінімальне значення;
- h — ширина інтервалу;
- i — номер інтервалу.

У коді це реалізовано так:

```
left = min_hist + i * width;  
right = min_hist + (i + 1) * width;
```

Після визначення меж інтервалів у програмі відбувається підрахунок кількості елементів у кожному інтервалі. Ця кількість називається частотою.

Частота i-го інтервалу позначається як:

n_i -к-ть елементів, що потрапили в i-й інтервал

У кодї це реалізовано через масив frequency, де кожен елемент відповідає своєму інтервалу:

```
frequency[idx]++;  
total++;
```

Таким чином:

- frequency[i] зберігає кількість елементів у i-му інтервалі;
- total зберігає загальну кількість усіх доданих елементів.

Це дозволяє працювати з гістограмою без збереження всіх окремих значень вибірки, використовуючи лише їх розподіл по інтервалах.

Далі додали дані до гістограми з файлів. Це дозволило обробляти великі обсяги даних без їх ручного введення.

У програмі реалізовано зчитування з текстового файлу. Дані читаються послідовно як числа типу double і одразу додаються до гістограми:

```
while (f >> x) {  
    addNumber(x);}
```

Таким чином, кожне число з файлу обробляється так само, як і введене вручну — визначається його інтервал і збільшується відповідна частота.

Також реалізовано зчитування з бінарного файлу. У цьому випадку дані читаються у форматі double без перетворення тексту:

```
while (f.read((char*)&x, sizeof(double))) {  
    addNumber(x);}
```

Цей спосіб є більш ефективним, оскільки працює без текстового парсингу і дозволяє швидше обробляти великі масиви даних.

Також передбачено другий спосіб додавання чисел до гістограми — коли значення можуть виходити за межі заданого інтервалу [min_hist, max_hist] [min_hist, max_hist][min_hist, max_hist].

У кодї це виглядає так :

```
if (x < min_hist) {  
    idx = 0;}  
else if (x >= max_hist) {  
    idx = M - 1;}  
else {  
    idx = (unsigned)((x - min_hist) / width);}
```

Після визначення індексу значення додається до відповідного інтервалу:

```
frequency[idx]++;  
total++;
```

Тобто враховуються усі значення навіть ті, що виходять за межі діапазону, вони не витрачаються, а додаються до крайніх інтервалів.

Середнє значення гістограми обчислюється як зважене середнє центрів інтервалів, де вагами є частоти.:

$$\bar{x} = \frac{\sum c_i n_i}{N}$$

де:

- c_i — центр i-го інтервалу;
- n_i — частота i-го інтервалу;
- N — загальна кількість елементів.

У кодї це реалізовано так:

```
s += c * frequency[i];  
return s / total;
```

Отже програма проходить по всіх інтервалах, бере центр кожного та множить його на к-сть елементів у цьому інтервалі, потім підсумовує все і ділить на загальну к-сть елементів.

Медіана — це значення, яке ділить вибірку на дві рівні частини.
Для інтервального розподілу використовується формула:

$$Me = L + \frac{(\frac{n}{2} - F)}{f} \cdot w$$

де:

- Me — медіана;
- L — ліва межа медіанного інтервалу;
- n — загальна кількість елементів;
- F — накопичена частота до медіанного інтервалу;
- f — частота медіанного інтервалу;
- w — ширина інтервалу.

У коді це реалізовано так:

```
unsigned half = total / 2;
unsigned F = 0;
for (unsigned i = 0; i < M; i++) {
    if (F + frequency[i] > half) {
        L = min_hist + i * width;
        return L + ((double)(half - F) / frequency[i]) * width; }
    F += frequency[i];}
```

Тобто спочатку знаходиться середина вибірки потім накопичуюється частота інтервалів і шукається інтервал де лежить середина.

Дисперсія показує, наскільки значення розкидані відносно середнього значення.

Формула для гістограми:

$$S^2 = \frac{\sum n_i (c_i - \bar{x})^2}{N}$$

де:

- S^2 — дисперсія;
- c_i — центр i-го інтервалу;
- $\bar{x}$ — середнє значення;
- n_i — частота інтервалу;
- N — загальна кількість елементів.

У коді це реалізовано так:

```
s += frequency[i] * (c - m) * (c - m);
return s / total;
```

Для кожного інтервалу береться його центр, знаходиться відхилення від середнього значення, це відхилення підноситься до квадрату, множиться на частоту, після чого всі значення підсумовуються і діляться на загальну кількість елементів.

Середнє відхилення показує, наскільки в середньому значення відхиляються від середнього значення вибірки.

Формула:

$$D = \frac{\sum n_i |c_i - \bar{x}|}{N}$$

де:

- D — середнє відхилення;
- c_i — центр i-го інтервалу;
- $\bar{x}$ — середнє значення;
- n_i — частота;
- N — загальна кількість елементів.

У кодi ми реалізували це так:

```
diff = c - m;  
if(diff < 0){  
    diff = -diff;  
}  
s += frequency[i] * diff
```

Сенс формули середнього відхилення полягає у визначенні того, наскільки далеко в середньому значення знаходяться від середнього значення вибірки.

Асиметрія показує, наскільки розподіл даних є симетричним відносно середнього значення.

$$A = \frac{\mu_3}{\sigma^3}$$

де:

- A — асиметрія;
- μ_3 — третій центральний момент;
- σ — стандартне відхилення.

Третій центральний момент обчислюється за формулою:

де:

$$\mu_3 = \frac{\sum n_i (c_i - \bar{x})^3}{N}$$

- c_i — центр i-го інтервалу;
- $\bar{x}$ — середнє значення;
- n_i — частота інтервалу;
- N — загальна кількість елементів.

У кодi це реалізовано так:

```
s += frequency[i] * (c - m) * (c - m) * (c - m);  
mu3 = s / total;  
return mu3 / (sigma * sigma * sigma);
```

Сенс формули полягає у визначенні того, чи є розподіл симетричним, чи має “довший хвіст” зліва або справа.

Для кожного інтервалу береться його центр, знаходиться відхилення від середнього значення, це відхилення підноситься до третього степеня, множиться на частоту, після чого всі значення підсумовуються і діляться на загальну кількість елементів.

Експес показує, наскільки розподіл є гостровершинним або плосковершинним порівняно з нормальним розподілом.

$$E = \frac{\mu_4}{\sigma^4} - 3$$

де:

- E — експес;
- μ_4 — четвертий центральний момент;
- σ — стандартне відхилення.

Четвертий центральний момент обчислюється за формулою:

$$\mu_4 = \frac{\sum n_i (c_i - \bar{x})^4}{N}$$

де:

- c_i — центр i-го інтервалу;
- $\bar{x}$ — середнє значення;
- n_i — частота інтервалу;
- N — загальна кількість елементів.

У кодi ми реалiзували це так:

```
s += frequency[i] * (c - m) * (c - m) * (c - m) * (c - m);
mu4 = s / total;
return mu4 / (sigma * sigma * sigma * sigma) - 3;
```

Сенс формули полягає у визначенні того, наскільки вершина розподілу є більш гострою або більш плоскою порівняно з нормальним розподілом.

Для кожного інтервалу береться його центр, знаходиться відхилення від середнього значення, це відхилення підноситься до четвертого степеня, множиться на частоту, після чого всі значення підсумовуються і діляться на загальну кількість елементів.

Мода гістограми — це значення, яке зустрічається найчастіше, тобто інтервал з найбільшою частотою. На гістограмі мода відповідає найвищому стовпчику

$$Mo^* = x_{i-1} + \frac{n_{Mo} - n_{Mo-1}}{2n_{Mo} - n_{Mo-1} - n_{Mo+1}} \cdot h$$

де:

- Mo^* — мода гістограми;
- x_{i-1} — ліва межа модального інтервалу;
- n_{Mo} — частота модального інтервалу;
- n_{Mo-1} — частота попереднього інтервалу;
- n_{Mo+1} — частота наступного інтервалу;
- h — ширина інтервалу.

У кодi це реалізовано так:

```
numerator = (double)n_mode - n_prev;
denominator = 2.0 * n_mode - n_prev - n_next;
return left + (numerator / denominator) * width;
```

Сенс формули полягає у знаходженні найбільш типового значення розподілу за інтервалом з найбільшою частотою.

Для знаходження моди визначається інтервал з найбільшою частотою, після чого з урахуванням сусідніх інтервалів обчислюється наближене значення моди всередині цього інтервалу.

Розмах гістограми показує різницю між максимальним і мінімальним значеннями.

Формула:

У кодi це реалізовано так:

$$R = x_{max} - x_{min}$$

Сенс формули полягає у визначенні ширини проміжку, в якому знаходяться всі значення гістограми.

Критерій Пірсона ми використали для перевірки того, наскільки розподіл даних гістограми є близьким до нормального розподілу.

$$\chi_e^2 = \sum_{i=1}^k \frac{(n_i - f_i)^2}{f_i}$$

де:

- χ_e^2 — значення критерію Пірсона;
- n_i — реальна частота інтервалу;
- f — теоретична частота інтервалу;
- k — кількість інтервалів.

У коді це реалізовано так:

```
diff = frequency[i] - expected[i];  
s += diff * diff / expected[i];
```

Сенс формули полягає у порівнянні реальних частот гістограми з теоретичними частотами нормального розподілу.

Для кожного інтервалу знаходиться різниця між реальною та теоретичною частотами, ця різниця підноситься до квадрату, ділиться на теоретичну частоту, після чого всі значення підсумовуються.

Висновок:

У нашому проєкті «Histogram» ми зробили програму для побудови і аналізу гістограми частот мовами програмування C та C++. Ми створили структуру для зберігання даних у вигляді інтервального розподілу та реалізували методи для додавання чисел у гістограму, роботи з текстовими та бінарними файлами, а також обчислення основних статистичних характеристик.

Програма дозволяє обробляти великі обсяги даних без збереження всієї вибірки, виконувати статистичний аналіз розподілу та оцінювати його основні властивості, зокрема середнє значення, розкид, симетричність та наближеність до нормального розподілу.

Джерела:

<https://drive.google.com/file/d/10UJJUXkfgVeY1mDrbWOIfkMN1Xw8R0u/view>

<https://www.statology.org/histogram-mean-median/>

<https://studfile.net/preview/7818855/page:20/>

https://biology.univ.kiev.ua/images/stories/Upload/Kafedry/Biofizyky/Biblioteka/Teoriya_ymovirnostey/teor2/Teoriya_ymovirnostey_2_mat_chast.Pdf

https://elib.lntu.edu.ua/sites/default/files/elib_upload/ЕНП_Якимчук_Селпина/page30.html

<https://studfile.net/preview/10442958/page:11/>

https://uk.wikipedia.org/wiki/Коефіцієнт_ексцесу